



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 文本分类中 Prompt Learning 方法研究综述
作者: 顾勋勋, 刘建平, 邢嘉璐, 任海玉
网络首发日期: 2023-12-12
引用格式: 顾勋勋, 刘建平, 邢嘉璐, 任海玉. 文本分类中 Prompt Learning 方法研究综述[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20231211.1556.004>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

文本分类中 Prompt Learning 方法研究综述

顾勋勋¹, 刘建平^{1,2}, 邢嘉璐¹, 任海玉¹

1.北方民族大学 计算机科学与工程学院, 银川 750021

2.北方民族大学 图像图形智能处理国家民委重点实验室, 银川 750021

摘要：文本分类是自然语言处理中的一项基础任务，在情感分析、新闻分类等领域具有重要应用。相较于传统的机器学习和深度学习模型，提示学习可以在数据不足的情况下通过构建提示来进行文本分类。近年来，GPT-3 的出现推动了提示学习方法的发展，并且在文本分类领域取得了显著的进展。该论文首先对以往的文本分类方法进行简要梳理，分析其存在的问题与不足；其次阐述了提示学习的发展进程，以及构建提示模板的方法，并对用于文本分类的提示学习方法研究及成果进行了介绍和总结；最后对于提示学习在文本分类领域的发展趋势和有待进一步研究的难点进行了总结和展望。

关键词：提示学习；文本分类；情绪分析；新闻分类

文献标志码：A **中图分类号：**TP391 **doi：**10.3778/j.issn.1002-8331.2310-0049

Text Classification: A Comprehensive Review of Prompt Learning Methods

GU Xunxun¹, LIU Jianping^{1,2}, XING Jialu¹, REN Haiyu¹

1. College of Computer Science and Engineering, North Minzu University, Yinchuan 750021

2. The Key Laboratory of Images & Graphics Intelligent Processing of State Ethnic Affairs Commission, North Minzu University, Yinchuan 750021, China

Abstract: Text classification is a basic task in natural language processing, which has important applications in sentiment analysis, news classification and other fields. Compared with traditional machine learning and deep learning models, prompt learning can construct prompts for text classification in the case of insufficient data. In recent years, the emergence of GPT-3 has promoted the development of cue learning methods, and has made significant progress in the field of text classification. Firstly, this paper briefly combs the process of previous text classification methods and analyzes their existing problems and shortcomings. Secondly, it expounds the development process of cue learning and the method of constructing cue templates, and introduces and summarizes the research and results of cue learning methods for text classification. Finally, the development trend and difficulties to be further studied in the field of text classification were summarized and prospected.

Key words: prompt learning; text classification; sentiment analysis; news classification

在自然语言处理 (natural language processing, NLP) 领域，文本分类是一项基本任务，其目标是将文本数据分配到预定义的标签或类别中^[1]。近年来，随着信息技术的迅速发展，网络上的文本信息急剧增加，

以及文本数据的非结构化特性，导致从中提取有用的信息变得非常困难^[2]。然而自然语言处理应用中所需的文本数据规模却不断扩大^[3]，这使得文本分类技术愈加重要。以前的文本分类研究方法通常以基于机器

基金项目：宁夏重点研发计划（引才专项）项目（2022BSB03044）；宁夏自然科学基金项目（2021AAC03205）；北方民族大学学科研启动金项目(2020KYQD37)。

作者简介：顾勋勋(1998—)，男，硕士研究生，CCF 会员，研究方向为智能信息检索与推荐、文本分类；刘建平(1989—)，通信作者，男，博士，讲师，研究方向为智能信息检索与推荐，E-mail: liujianping01@nmu.edu.cn；邢嘉璐(2000—)，男，硕士研究生，CCF 会员，研究方向为跨模态图文检索；任海玉(2000—)，女，硕士研究生，研究方向为智能信息检索与推荐。

学习和深度学习为主,但是机器学习方法存在着维度爆炸、数据稀疏以及有限的泛化能力等缺陷^[4]。同时基于深度学习的文本分类模型需要大量的标注数据进行训练,但获取这样的标注数据通常较为困难。因此,目前的传统文本分类方法已经无法完全满足需求。在信息爆炸的时代,大量文本数据涌现^[5],使用传统的深度学习和机器学习方法进行文本分类既耗时又充满挑战,往往难以实现高效的分类任务^[6]。

近年来,随着预训练语言模型(Pretrained Language Models, PLMs)的迅猛发展,模型参数不断膨胀,这使得传统的预训练-微调范式难以满足不断变化的需求。随着 GPT-3 的崭露头角,提示学习(Prompt Learning)开始引起广泛关注。提示学习是在文本提示的协助下,重新构建下游任务^[7]。通过适当的提示,预训练语言模型本身能够预测所需的输出,有时甚至不需要任何额外的特定训练,从根本上减少了所需的参数量。其通过选择适当的提示来引导模型的预测输

出,使得完全无监督训练的 PLMs 能够应用于解决各种下游任务,成为一种前景广阔的方法^[8]。在文本分类中,提示学习技术的应用使得模型能够根据特定的提示信息更准确地进行分类,从而提高了文本分类任务的效率和准确性。

如图 1 所示,预训练-微调与提示学习于应用上区别是:前者让模型适应下游任务:通过“预训练+微调”策略,模型学习大量文本数据,获取广泛的语义信息和初始化参数。随着模型规模增大,硬件和数据需求上升,不同下游任务的多样性使得微调设计变得复杂,模型需要克服领域差异,导致优化成本增加。而后者让下游任务适应模型:通过预训练模型自动预测输出,无需特定训练。将下游任务转为预训练任务,发挥模型内在能力。这简化了模型的设计和优化过程,降低了硬件和数据的需求。提示学习让下游任务适应模型,提高了模型分类准确性,提升文本分类效率。

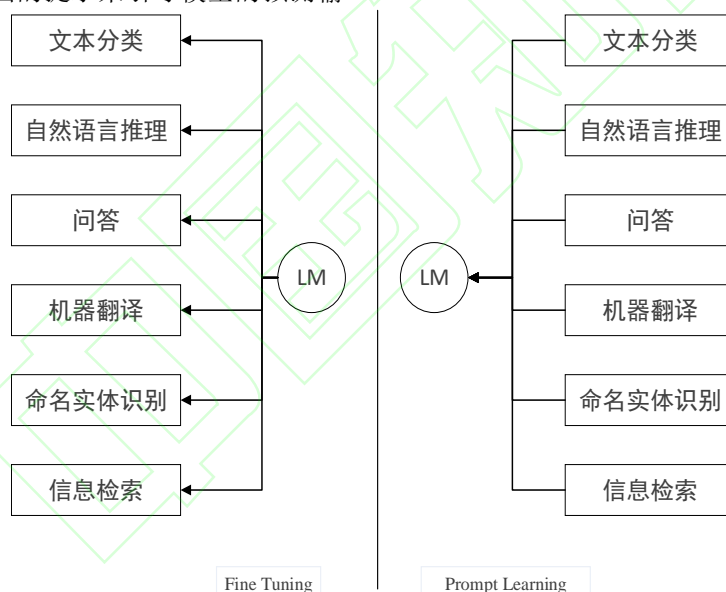


图 1 预训练-微调与提示学习应用对比图

Fig.1 Comparison chart of pretraining-finetuning and prompt learning applications

过去的研究主要侧重于基于提示学习的文本分类方法,缺乏对这些方法进行全面综述。本文旨在提供一份简明而专业的综述,对当前文本分类领域中基于提示学习的发展进行全面探讨。我们详细介绍了当前文本分类研究中的最新技术方法,为研究人员提供了一个便捷这一领域最新进展的途径。

1 提示学习概述

随着预训练语言模型如 ELMO^[9]、GPT^[10]、BERT^[11]的不断发展,预训练-微调的方式在许多自然语言处理(NLP)任务中被广泛采用。在自然语言处理领域,预训练语言模型已成为一种重要的技术范式^[12]。预训练语言模型首先在丰富的原始文本数据上进行训练,以在大规模数据集上进行应用,并在训练过程中学习通用的语言特征^[13]。通过引入额外的参数并

使用适用于特定任务的目标函数对语言模型进行微调,使其适应各种下游任务^[14]。预训练语言模型在海量文本上进行了训练,学习了丰富的语言表示知识。然而,由于训练阶段和下游任务的目标不匹配,导致预训练语言模型没有充分利用其所嵌入的丰富语义信息和语言知识,严重影响了模型在下游任务中的性能同时随着预训练模型的不断发展,模型参数的规模甚至已经达到了 100 亿级别,这导致在实际应用中变得异常困难。且随着预训练模型的参数量越来越大,若为某个下游任务去微调模型,会造成资源的极大浪费。

为了应对这一问题,提示学习在自然语言处理领域中崭露头角,成为一种新的范式。提示学习不再通过目标工程来使预 PLMs 适应下游任务,而是在文本提示的协助下,重新构建下游任务,使其更像是在原

始 LM 训练期间解决的任务^[15], 减少了模型所需的参数量。用户通过设计或选择提示, 将其输入到模型中, 模型根据这些提示进行预测或生成。微调的过程使模型适应于具体的分类任务, 而不需要大规模重新训练。在文本分类中, 用户通过设计或选择提示, 将其输入到模型中, 模型根据这些提示进行预测或生成。微调的过程使模型适应于具体的分类任务, 而不需要大规模重新训练。通过适当的提示, PLMs 本身能够预测所需的输出, 有时甚至不需要任何额外的特定训练。这种方法实质上是将下游任务整合为预训练任务, 并通过特定的模块将下游任务的数据转换为自然语言形式, 充分发挥预训练模型的内在能力。

提示学习过程包含三个主要步骤: Prompt 添加、

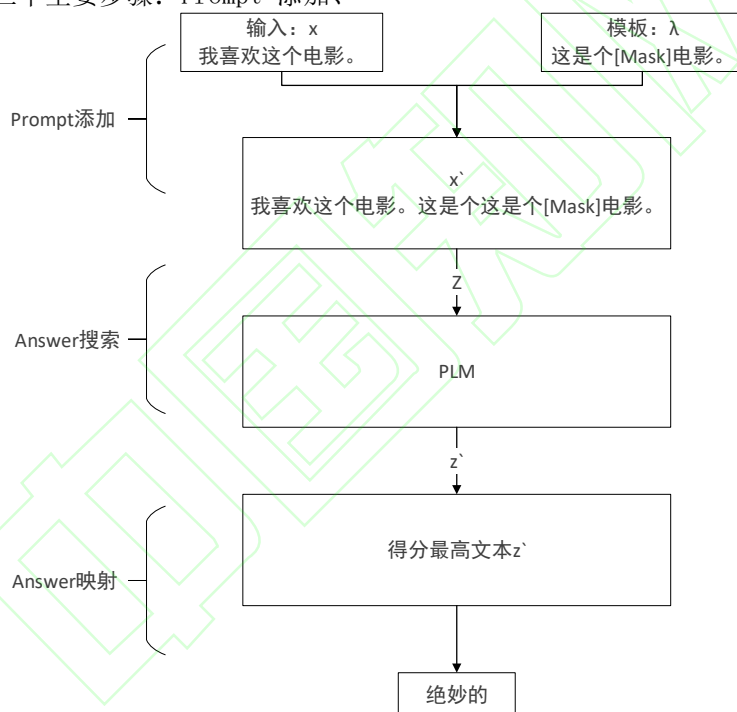


图2 提示学习流程

Fig.2 Workflow of prompt learning

在传统的基于深度学习的监督方法中, 输入通常为文本数据 x , 通过模型 $P(y|x; \theta)$ 对输出 y 进行预测。然而, 监督学习面临的主要挑战之一是, 为了训练模型 $P(y|x; \theta)$, 必须获取适用于训练任务的监督数据, 而寻找这样的数据往往具有相当的困难。基于提示学习是一种自监督学习方法, 是旨在通过对输入文本 x 自身的语言模型概率进行建模, 从而实现避免对大规模训练数据集的依赖。具体而言, 在提示学习中, 原始输入 x 通过提示模板的修饰, 生成一个新的输入 V , 其中包含待填充的槽位。随后, 通过语言模型建模 $P(x'; \theta)$, 最终通过解析并获取提示模板中槽位的最高预测概率, 实现对最终预测标签 y 的输出。这一方法的关键在于利用提示模板对输入进行调整, 使得模型更加灵活地适应各种任务, 减轻了对大量监督数据集的依赖。

Answer 搜索和 Answer 映射^[16]。如图 2 所示: 首先, 通过手动或自动设计合适的提示, 将下游任务转化为预训练模型可理解和处理的形式。这些提示需考虑任务的语言表达方式、逻辑结构和任务要求, 以确保模型能够准确理解任务。其次, 通过进行 Answer 搜索, 获得预训练语言模型对下游任务的预测输出。这一过程涉及搜索得分最高的文本 z' , 以最大化 PLM 的得分, 找到与任务相关的输出, 以获得预期的答案。最后, 在完成 Answer 搜索后, 需要将搜索得到的答案映射到下游任务所需的标签或类别, 以使模型的输出符合下游任务的要求。此映射过程可以是简单的匹配, 也可以通过设计复杂的映射函数来转换输出。

2 Prompt Learning 在文本分类中应用

文本分类的目标是为未标注的句子分配预定义的标签, 通常需要大量的标注数据来支持, 然而在实际应用中, 获取大量标注数据往往是困难的。特别是当只有少量标注样本时, 文本分类任务往往难以实现。标记样本不足已成为自然语言处理文本分类的重要问题。提示学习通过借助提示重构下游任务, 以解决数据不足的问题^[17], 在取得了令人满意的性能方面取得了显著成果。

目前, 文本分类领域有三种主要的提示学习方法, 分别是基于人工方法构建 Prompt 模块的文本分类、基于离散方法构建 Prompt 模块的文本分类以及基于连续构建 Prompt 模块的文本分类。这些方法在文本分类研究中扮演着重要角色, 接下来, 将以此为切入点, 分析它们在文本分类领域的应用现状。

在提示学习的领域中,合理的提示模板设计对于确定是否能够成功完成下游任务具有极其重要的作用。

为了使后续的研究更具可追溯性和可理解性,表1对本文中所主要采用的提示模板进行了综合总结和归纳:

表1 主要的提示学习模板汇总

Table 1 Summary of key prompt learning templates

方法	提示模板	描述
PET ^[20]	$P = \text{It was [Mask].a}$	a 为输入文本
AUTOPROMPT ^[25]	$\{\text{sentence}\} [T] [T] [T] [T] [T] [P]$	{sentence} 是一个占位符,可替换为具体的句子
LM-BFF ^[26]	$T=X. \text{It was [MASK].}$	X 是输入句子
WARP ^[32]	$[\text{CLS}] \text{ "S1" ? [MASK]. "S2" ! [SEP]}$	"S1"和"S2"是具体的句子内容
P-Tuning ^[33]	$T = \{[P0:i], x, [Pi+1:m], y\}$	X 是上下文, y 是目标
MP ^[39]	Premise.Question:Hypothesis <v1>...<v4>Answer:..	<v1>到<v4>是随机初始化的可训练向量
PPT ^[40]	$x_p = [\text{CLS}] A [\text{MASK}] \text{ question : } x$	x 是输入序列
KPT ^[42]	$x_p = [\text{CLS}] A [\text{MASK}] \text{ question : } x$	x 是输入序列
UPT ^[43]	$[\text{<s>}. \text{Is } \langle x1 \rangle \text{ or } \langle x2 \rangle ? \text{It was [MASK].}$	s 是输入句子, x1, x2 是标签词
PLST ^[44]	$x_p = [\text{CLS}] x, a [\text{MASK}] \text{ question}$	X 是输入句子
TransPrompt ^[48]	$P(m)1, \dots, P(m)i, x, P(m)i+1, \dots, P(m)I, \text{MASK}$	$P(m)i$ 是一个提示伪标记, I 是伪标记的总数
PINPOM ^[52]	$[\text{CLS}] x ? [\text{MASK}], W [\text{SEP}]$	x 是输入文本, y 是类名
AMuLaP ^[56]	$[\text{CLS}] s. \text{It was [MASK]. [SEP]}$	S 为输出句子
BERT-P-Tuning ^[57]	$p = u1, u2, [\text{mask}], u3, u4$	[u1]~[u4]代表词表的[unused1]~[unused4]
CIPLUD ^[58]	$U1, \dots, U_m, \langle \text{MASK} \rangle 1 \dots, \langle \text{MASK} \rangle 2$	$U1, \dots, U_m$ 为可学习的张量
PTMLTC ^[59]	$\text{eprompt} = [\text{CLS}]x. \text{It belongs to [MASK].}$	x 为输入练习文本

在将提示学习应用于具体下游任务的训练过程中,通常模型结构包含以下两种参数形式:预训练模型参数和提示模板参数。当部分或全部模型参数需要更新时,这将对整个模型性能产生重大影响,因此产生了不同的训练策略。一、冻结预训练模型及提示模板参数,即是可直接通过模型预测结果,通常应用于零样本学习问题;二、冻结预训练模型参数、仅更新提示模板参数可使模型专注于任务要求;三、而仅更新预训练模型参数而冻结提示模板参数,这一策略的目的是保留提示模板的结构,以确保模型在特定任务中保持对提示的敏感性,同时充分利用预训练模型的通用知识;四、而对于更大样本或复杂任务,可能需考虑更新整个模型参数,尽管这可能需要更多训练数据和计算资源。

因此,提示学习成功应用需要合理选择和调整这些策略,以在下游任务中获得卓越性能并最大化预训练模型通用知识的利用。

提示模板的构建对于下游任务能否成功至关重要。目前,主要存在三种构建提示模板的方法:人工构建模板、离散构建模板以及连续构建模板。这些方法所构建的模板各有特点,接下来,我们将详细介绍这三种方法的具体操作及其在文本分类中的应用。

2.1 基于人工构建提示模板

手工构造提示方法是通过手动编写输入提示,以引导模型生成所需的输出。这种方法的优点是灵活性较高,可以根据特定的任务和数据集来设计提示。然而,手工构造提示需要一定的专业知识和经验,而且可能需要大量的时间和资源。Petroni F 等人^[18]引入了 LAMA 数据集,用于测试语言模型对事实和常识知识的理解。该数据集由一组数据源组成,每个数据源包含一组事实,其中这些事实可以是三元组或答案对。将每个事实转换成“完形填空”形式的陈述句(如表2所示),然后用于从语言模型中查询目标标记,以测试

模型对知识的预测。例如,对于事实(Dante, born-in, Florence),可以将其转换为陈述句“Dante was born-in [Mask]”,并用于查询模型是否包含该知识。Brown T 等人^[19]创建了手工制作的前缀提示,用于处理多种任务,包括问答、机器翻译和常识推理。在 zero-shot、one-shot 和 few-shot 设置下,这些前缀提示在许多 NLP 任务和基准测试中展现出强大的性能。Schick T 等人^[20]等针对文本分类和条件文本生成任务,通过使用预定义的模板将原始文本转化为“完形填空”形式,有助于语言模型理解下游任务,尤其是在小样本学习设置中,当只有少量样本时,让模型理解任务的关键变得更具挑战性。

表2 模板构建示例

Table 2 Template construction example

问题	答案
法国的首都都是_____。	巴黎
中国的国宝是_____。	大熊猫
中国的国粹是_____。	京剧
字节跳动是一个_____。	公司

2.2 基于离散构建提示模板

离散提示是让模型在一组离散模板的空间中选择一个最优的模板。离散提示模块预定义提示根据用户行为触发,反应灵活且成本低,但难以覆盖所有情况。Jiang Z 等人^[21]中的 MINE 方法采用挖掘的方式,从包含输入 x 和输出 y 的文本中自动发现模板。该方法从文本语料库(如 Wikipedia)中抓取数据,然后寻找输入和输出之间的依赖路径。Yuan W 等人^[22]利用同义词库中的短语替换,将提示语在不同语言之间来回转换并返回。值得一提的是, Haviv A 等人^[23]在输入 x 输入到提示模板后执行释义,允许对每一个输入都产生不同的解释。Wallace E 等人^[24]引入了梯度引导搜索标记方法,通过迭代更新触发序列中的标记,以增加批量示例的目标预测可能性。将短序列连接到文本分类、条件文本生成和阅读理解的输入中,从而成功

地触发目标预测。由于触发器与输入无关,该方法为分析全局模型行为提供了手段,证实了 SNLI 模型对数据集偏见的利用,有助于诊断阅读理解模型的启发式学习。Shin T 等人^[25]通过在下游应用中自动搜索训练样本的模板令牌,实现了良好的提示应用效果。Gao T 等人^[26]将提示生成视为文本生成任务,使用标准的自然语言生成模型来执行这一任务。具体来说,(1)采用基于提示的微调与自动搜索提示;(2)将选定的任务演示(训练示例)作为输入上下文的一部分。Davison J 等人^[27]使用大型预训练语言模型生成常识性知识,通过填充提示来解决常识性知识挖掘问题。

2.3 基于连续构建提示模板

连续的模板构建法旨在使模型在训练过程中根据具体的上下文语义和任务目标对模板参数进行连续调整。连续提示是在预训练语言模型的嵌入空间中执行的一种提示方法,即在输入序列中添加一系列特定于任务的向量,这些向量不必是自然语言单词的嵌入。与由预训练语言模型参数决定的离散提示不同,连续提示中,模板的参数独立于预训练语言模型参数。Li X 等人^[28]引入了一种 Prefix-Tuning 方法,适用于自然语言处理生成任务。该方法在固定预训练语言模型参数的基础上,只微调少量可训练参数,将离散标记优化为连续词嵌入。该方法添加了一系列任务特定向量作为输入前缀,并保持预训练模型参数不变。Lester B 等人^[29]在输入词嵌入前添加前缀提示,微调时保持

上游模型参数不变,仅更新少量参数。Zhong Z 等人^[30]提出 OptiPrompt,使用人工构造的 prompt 初始化连续型 prompt,长度和位置由人工构建的 prompt 确定,训练时仅更新连续型 prompt 的词嵌入。Qin G 等人^[31]引入了 soft 混合模型,将由连续向量组成的提示模块应用于任务,优化提示的混合方式以及如何整合这些提示。Hambardzumyan K 等人^[32]不仅优化 Prompt 参数,还引入了与答案相关的参数,同时将手工提示模板与连续模板结合起来。Liu X 等人^[33]通过在嵌入式输入中插入可训练变量来学习连续提示,使 GPT 在 NLU 任务上超越或与同样大小的 BERT 相媲美。Liu X 等人^[34]所提出的 P-tuning V2 是对 P-tuning 和 Prefix-tuning 的进一步优化,其引入深度提示编码策略,微调深层模型参数,采用多任务学习提高效率,可支持句子级和标记级输出。Han X 等人^[35]提出了 PRT,使用逻辑规则构建多个子提示,将每个类的先验知识编码进提示模板,可使用预定义的逻辑规则将子提示组合成完整的任务特定提示。

2.4 小结

本章分别从人工模板构建、离散模板构建、连续模板构建三种模板构建方法应用于文本分类进行介绍。如表 3 所示,对三种模板构建方式的优缺点进行总结归纳。并对三种构建方式下不同的模板所使用的预训练语言模型,以及核心思想与优缺点进行分析梳理,如表 4 所示。

表 3 模板构建方法比较

Table 3 Comparison of template construction methods

模板构建方法	优点	缺点
人工构建模板	通过直观模板引导语言模型学习和推理,少例即可执行新语言任务。	需要专家知识,耗时费力;且难以适应复杂任务,限制模型的通用性。
离散构建模板	自动找到模板,无需手动构建,提升效率准确性。	受限于文本语料库的质量和覆盖范围,可能无法找到所有的模板。
连续构建模板	允许在模型的嵌入空间中执行连续提示,不限制为人类可解释的自然语言,提高了灵活性。	需要更多的参数和计算资源,增加了模型的复杂性和训练的时间成本。

表 4 各种模板构建方法比较

Table 4 Comparison of various template construction methods

构建提示方法	提示方法	预训练语言模型	核心思想	优缺点
人工构建模板	PET	RoBERTa	将输入示例重新构造为填空样式的短语。	利用预训练模型知识助力下游任务,但需要大量的标注数据。
	iPET	RoBERTa	通过多次迭代地在逐渐增大的训练集上训练多个模型。	通过多次迭代训练提高模型的性能,但是增加计算资源和时间的消耗。
	BARTScore	BART	根据生成文本与参考文本之间的相似度来评估生成文本的质量。	不需要人工评价来进行训练,在低质量文本时效果较差。
	BERTese	BERT	通过自动重写查询语句来优化知识提取。	可以直接优化以获得更好的知识提取,需要额外的处理和训练。
离散构建模板	AdvTrigger	GPT-2	通过在文本中插入特定的触发词序列来改变模型的预测结果。	可以生成适用于任意输入的触发序,依赖白盒访问,可解释性有限。
	AUTOPROMPT	BERT	通过构建特定任务的提	自动生成适合的提示,提

连续 构造 模板	LM-BFF	RoBERTa	示来引导语言模型产生所需的知识。 通过使用自动生成的提示来提高任务的性能和泛化能力。	示缺乏可解释性,对训练数据要求较高。 可自动获取有效的提示,在处理复杂任务时性能相对较低。
	Prefix-Tuning	BART	通过优化连续的前缀来引导语言模型生成	根据任务结果进行优化,参数较多。
	Prompt Tuning	T5	通过添加特定的提示,以指导模型在下游任务中的生成。	提高了模型的适应性,减少了参数量,与其性能仍然存可提高。
	OptiPrompt	BERT	在连续嵌入空间中直接优化提示。	训练更容易和更高效,但需要对模型白盒访问。
	Warp	RoBERTa	通过在输入中添加额外的标记来利用预训练语言模型的能力。	使用的参数较少,效果有时不稳定。
	P-Tuning	GPT-2	通过在连续空间中自动搜索提示来改进预训练模型的性能。	自动搜索连续的提示,从,但需更长的时间来搜索最佳的连续提示。
	P-Tuning V2	BERT	将离散提示令牌替换为可训练的连续并嵌入。	具有普适性,对超参数比较敏感。
	PTR	RoBERTa	将逻辑规则与提示调优相结合。	提高模型性能,提示构建较为耗时。

3 增强式提示学习在文本分类中的应用

3.1 多种提示方法的混合策略

为了充分利用人工设计的知识和预训练模型的泛化能力,学术界提出了将离散提示和连续提示结合,手工提示与连续提示结合,手工提示与离散提示结合的方法,通过混合训练这两种类型的提示,来进行模型优化。混合方法则结合了手工和自动生成提示,以及融合离散提示和连续提示的优点,可以提高模型的多样性和灵活性^[36]。通过将不同类型的手工模板和自动生成模板结合起来,可以更好地满足任务的多样性和复杂性,可以充分发挥两者的优势,同时弥补各自的不足。

手工提示和连续提示结合的方法可以充分发挥模型的潜力,手工提示可以通过人工设计的方式提供先验知识,有助于引导模型的学习方向,而连续提示则通过在输入序列中添加额外的标记来利用语言模型的能力。Hambardzumyan K 等人^[32]所提出的 WARP,在手工提示中,WARP 可以通过手动设计初始化的提示来注入知识。这对于样本数量较少的任务特别有用。而在连续提示中,WARP 通过在连续空间中学习提示嵌入来利用语言模型的能力。通过查看学习到的嵌入附近的标记向量,可以发现与任务相关的提示标记。Liu X 等人^[33]提出的 P-tuning 在本文中使用手工提示和连续提示来增强预训练模型的能力。手工提示是指人工设计的提示语,而连续提示是指将初始提示嵌入到模型输入的不同位置,并与预训练模型一起微调。通过 P-tuning,可以自动搜索更好的连续提示,从而提高预训练模型在自然语言理解任务上的性能。

手工提示和离散提示相结合的方法优点是可以提供更好的控制和灵活性。手工提示可以根据具体任务的需求设计,而离散提示则可以通过模板化的方式定义新的提示。离散提示可以提供更加精确的指导,而手工提示则可以根据具体任务需求进行调整和优化。

将这两种提示类型结合起来,可以同时保证模型的精确性和鲁棒性。离散提示可以针对不同的数据类型和任务进行生成,具有较广泛的适用范围。而手工提示则可以根据具体任务需求进行调整和优化,因此也具有较广泛的适用范围。Perez E 等人^[37]对于离散提示,本文使用了 LAMA 数据集和 LPAQA 数据集中的多个提示,通过交叉验证(CV)和最小描述长度(MDL)来选择最佳提示。对于手工提示,本文使用了先前的研究中设计的提示,并通过测试准确性来选择最佳提示。Aghajanyan A 等人^[38]所提出的 HTML 方法,手工提示可以利用 HTML 的语义来更好地控制模型的输出,通过要求模型填充网页中的<title>标签来进行零-shot 摘要生成。而离散提示则可以通过将示例任务格式化为 HTML 并模板化结果来定义新的提示。这种结合可以使模型在训练过程中更好地适应不同任务的需求,并提供更多的灵活性和控制能力。

将离散提示和连续提示结合的方法,即可以使用离散提示来引导模型对特定任务进行初始学习,又能为任务提供关键信息。随后,通过混合训练连续提示,模型可以进一步优化并增强在不同任务上的泛化能力。通过这种混合训练的方式,可以更好地利用现有的资源和数据,为自然语言处理领域带来更大的效益。Zhao M 等人^[39]在混合训练中,作者采用了同时包含离散提示和连续提示的方法。具体而言,作者采用软提示(soft prompts)和硬提示(hard prompts)的混合训练策略。软提示由连续的嵌入向量构成,而硬提示则由离散的语言短语构成。通过同时使用这两种类型的提示,旨在充分发挥它们的优势,以提升预训练语言模型的性能。Gu Y 等人^[40]聚焦于混合训练中离散提示和连续提示的应用。离散提示是通过人工设计的提示语来描述自然语言理解(NLU)任务,而连续提示则是在连续空间中通过随机梯度下降(SGD)进行学习。

离散提示的优点在于它能够提供更任务描述的可解释性，而连续提示则放宽了必须使用离散标记的限制。

3.2 基于外部知识库的增强策略

外部知识库是一种结构化的知识资源，它在文本分类任务中发挥关键作用，通过引用外部资源或数据库，为计算机程序和人工智能系统提供额外的知识信息。这些知识库包含了各种领域的知识和信息，不仅

包括结构化数据，还包括非结构化数据，以增强系统的智能决策和语义理解能力^[41]。通过外部知识库，模型能够在面对不同挑战时表现出更强的适应性，包括少样本学习、零样本学习、新任务的泛化等。如图 3 所示，基于外部知识的增强策略，通过提示学习和外部知识库结合，将提示模板的实体标签，输入知识库中进行扩展标签词，再输入到语言模型，达到文本分类的目的。

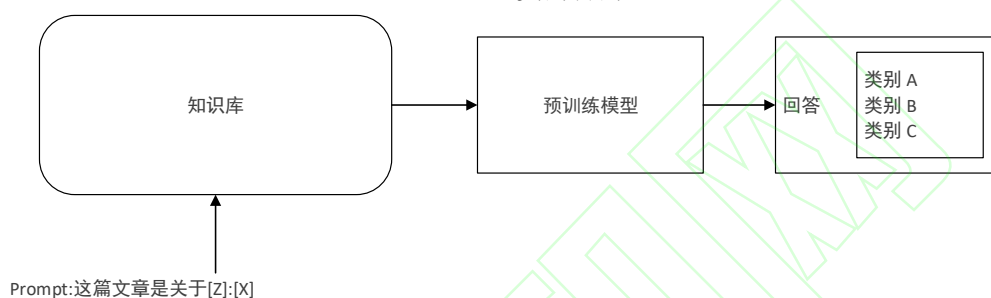


图 3 提示学习结合外部知识库

Fig.3 Prompt Learning integration with external knowledge base

Hu S 等人^[42]提出了一种利用外部知识库来扩展标签词的方法。在构建阶段，外部知识库生成每个标签的一组标签词，这些词汇不仅包括同义词，还涵盖了不同粒度和角度的词汇。接着，文中提出了四种细化方法，包括频率细化、相关性细化、上下文校准和可学习细化，用于处理无监督扩展中的噪声。最后，使用平均损失函数或加权平均损失函数将扩展的标签词的得分映射到标签得分上。Wang J 等人^[43]提出了一种 Options Knowledge Repository (OKR) 来实现标签词的自动扩展。方法包括以下步骤：首先，对语料库中的形容词进行词性标注和聚类，形成聚类中心和候选标签词。接着，在生成选项时，对于被掩盖的词，查询 OKR 中最不相似的聚类，从该聚类中随机选择一个形容词作为备选标签词。最后，将真实标签词和生成的备选标签词分别映射到“Class: Correct”和“Class: Incorrect”两个类别中，以实现标签词的自动扩展。Zhu Y 等人^[44]介绍了一种自动的标签词扩展方法。具体策略是从开放的知识图谱中检索与短文本

中实体相关的前 N 个概念，并计算选定概念与类别标签之间的距离，以进一步细化扩展的标签词。通过这种方法，可以自动扩展标签词集合，以提高短文本分类的性能。Wang L 等人^[6]介绍了一种标签词扩展方法，通过将外部知识库中的知识引入模型。该方法利用名为 CN-Probase 的外部知识库来自动为实体标注概念标签。具体步骤包括将每个样本的标题送入实体链接 API 服务以识别实体，保留只有一个实体的样本，将剩余样本的实体输入实体概念 API 服务中，以获取它们的概念标签。

在文本分类中，通过引入外部知识库以扩展原始的标签词，可以有效提升模型的泛化能力，避免预训练知识的灾难性遗忘。因此，可知大规模知识库对文本分类极具重要意义。目前，经过诸多学者的不断努力，已经研发了许多大规模的知识库。如表 5 所示，本文通过整理常用重要的知识库，根据它们的语言、目的、简介以及来源，旨在为后续相关研究提供便利。

表 5 常用外部知识库

Table 5 Common external knowledge bases

知识库	语言	目的	简介	来源
Probase	英文	捕获实体之间的语义关系和概率信息。	通过自动化方法从数十亿网页和文本数据中抽取概念（实体）、属性及关系。	微软
CN-Probase	中文	促进中文信息理解处理，并准确标注。	基于大规模中文文本数据集构建的概念图谱和概念分类体系。	复旦大学
WordNet	英文	旨在帮助人们理解词汇之间的关系和含义。	整理词汇为同义词集，每组包含相关语义词。	普林斯顿大学
ConceptNet	英文	旨在捕捉常识性的人类语言理解。	基于图结构的数据集，记录实体间关系丰富信息。	Open Mind Common Sense
Related Words	英文	用于提取与特定主	多个资源聚合，包括词嵌入、	多个资源聚合而成

		题相关的词语。	ConceptNet 和 WordNet 等。
OKR	英文	扩展模型在不同任务上的适应能。	基于语料库的形容词词性标注与聚类生成。
CN-DBpedia	中文	提供高质量的结构化数据,供机器和人使用。	从中文百科提取,经过过滤、融合,生成优质结构化数据。
XLORE	多语言	旨在支持跨语言的信息抽取和语义搜索。	融合 Wikidata 中的中英文信息和 BabelNet 的多语言词汇与关系。

3.3 提示学习与迁移学习的协同策略

提示学习通过引入提示信息帮助模型更好地理解 and 执行不同的任务,多是作用于下游任务学习中,为每个下游任务所特定的提示,但是不同下游任务之间的提示难以互用,在很大的程度上浪费了计算资源,消耗了大量时间^[45]。与此同时,迁移学习的目的是将知识或资源从源领域转移到目标领域,指的是将已有的知识或资源从一个领域迁移到另一个领域的过程。

并且迁移学习允许模型利用从先前任务中学到的知识和经验,快速适应新任务并提高性能^[46]。

以往的提示学习方法没有考虑到任务之间的迁移学习,当给定多个相似任务时,当使之学习特定任务和通用任务之间的提示嵌入,并要考虑任务之间的迁移性。如图 4 所示,提示学习与迁移学习协同训练,可在源任务上训练提示嵌入,以作为目标任务上的初始化。

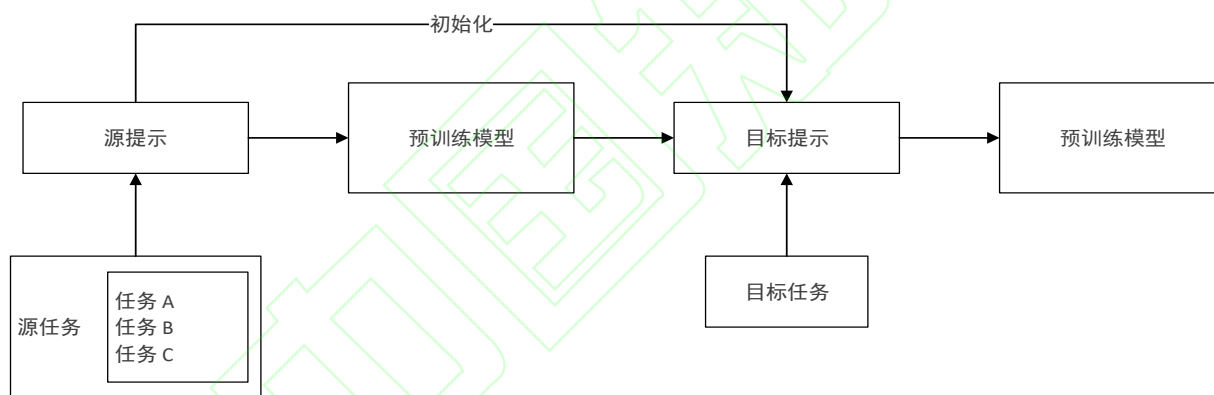


图 4 提示学习与迁移学习的协同

Fig.4 The synergy between prompt learning and transfer learning

Vu T 等人^[47]提出了 TransPrompt 框架,将提示学习和迁移学习相结合,以使预训练模型更快地适应新的文本分类任务。该框架引入了任务特定和任务通用的提示编码器,通过在多个源任务上进行预训练,将文本分类问题转化为完形填空任务,然后通过填充词预测和标签映射来获得分类结果。同时,通过元学习器 Fmeta,将从其他任务中学到的知识迁移到未曾见过的任务,以提升少样本学习下游任务的性能。Wang C 等人^[48]提出 SPOT 方法,该方法通过源任务的 Prompt-Tuning 方法来初始化目标任务的提示,并引入了一种

任务选择策略,将任务提示转化为任务嵌入,从中选择适合目标任务的任务。通过在源任务上进行提示微调,可以将学到的提示应用于目标任务。

在文本分类中,增强式提示学习通常采用:多种提示方法混合的策略、基于外部知识库的增强的策略、提示学习与迁移学习结合的协同策略。综合以上分析,下面就三种策略在文本分类应用中的优缺点进行对比,如表 6 所示,以便于更好地运用这些方法开展文本分类研究。

表 6 增强式提示学习在文本分类中的应用

Table 6 Enhanced prompt learning in text classification applications

增强式提示学习在文本分类中的应用	具体改进	优缺点
多种提示方法混合的策略	互相取长补短,提示模型多样性,强化模型可控性。	混合提示适用于低资源环境,但需要复杂模型和训练,增加资源成本。
基于外部知识库的增强策略	通过词性标注、聚类生成候选标签词,利用外	标签词扩展有利于模型泛化、避免过拟

	部知识库扩展每个标签的一组标签词。	合和灾难性遗忘,但需要人工定义标签词,依赖知识库资源。
提示学习与迁移学习结合的协同策略	通过在源任务上进行提示微调,然后将学到的提示应用于目标任务。	结合迁移学习下源任务提示初始化提升目标任务性能,多任务学习效果较差。

4 提示学习在文本分类场景的应用

在自然语言处理领域,零样本学习、小样本学习和多标签学习被认为是三个重要且具有挑战性的研究方向,而提示学习在这些场景下也受到了广泛的研究和应用。

零样本文本分类是指在训练阶段没有标记数据的情况下,将文本分类到在训练阶段未见过的类别。零样本文本分类的目标是通过学习文本和类别之间的匹配关系,将文本准确地分类到已见和未见的类别中。这意味着模型在没有任何关于这些类别的训练数据的情况下,能够对新的文本进行分类。传统的文本分类方法在没有相关类别的训练数据情况下很难完成文本分类。通过提示来帮助模型进行分类,往往能够取得很好的效果。

Wang S 等人^[49]通过将原始的 NLP 任务转化为文本蕴含任务,并利用对比学习进行数据增强。具体做法是将分类任务的标签转换为自然语言句子,并判断样本是否蕴含这些标签,从而在零样本学习中进行语言推理。Sun Y 等人^[50]提出了通过引入下一句预测(NSP)作为预训练任务,以提升模型理解输入语境和任务需求的能力。使用基于句子级预训练任务的 NSP-BERT 模型,实现了零样本和少样本学习,并在多个自然语言处理任务中取得了有竞争力的结果。Harrando I 等人^[51]通过提示学习方法结合上下文信息进行分类,同时利用 ConceptNet 的关系连接来解释文本分类结果,从而解决零样本分类的解释性、标签消歧和领域适应问题。Dan Y 等人^[52]提出通过两个步骤:提示插入(PIN)和提示匹配(POM),来完成零样本文本分类。在 PIN 步骤中,通过插入具有信息量的词语来生成类别描述。在 POM 步骤中,建立了提示匹配模型,用于学习文本和类别描述之间的匹配关系,在零样本文本分类达到很好的效果。

小样本文本分类是指在只有少量标记样本的情况下进行文本分类的任务^[53]。由于标注数据的成本高昂,在实际应用中通常只有很少的标记样本可用,因此小样本文本分类成为一个重要的研究领域。然而,将标准的监督学习方法应用于小训练集往往效果不佳,因为许多问题很难仅通过少量样本来理解。小样本文本分类是指在文本分类任务中,训练数据集规模较小的情况下进行分类。在这种情况下,由于训练数据的有限性,传统的机器学习方法或深度学习方法可能会面临过拟合、泛化能力不足等问题^[4]。

Schick T 等人^[20]提出半监督训练方法 PET,该方法通过将输入示例转换为完形填空短语,并为未标记的示例分配软标签,然后进行标准监督训练。这样的做法有助于语言模型更好地理解任务,从而实现小样本文本分类。Mayer C 等人^[54]探讨了基于 Transformer 模型的提示学习在文本分类任务中的优势,通过给定一个提示文本,语言模型可以根据其在训练数据中的概率来预测接下来最可能出现的词语。Song C 等人^[55]使用生成的自然语言序列作为提示,以缓解低资源情况下的分类问题。并且通过设计基于提示词的微调方法和中文提示词自动生成的流程,改进了提示的组合策略,从而提升了分类性能。Wang H 等人^[56]介绍了自动多标签提示(AMuLaP)方法,该方法通过模板将原始输入转换为基于提示的输入,然后使用预训练的语言模型填充掩码标记,并将填充的标记映射到相应的标签,从而提升分类性能。于碧辉等人^[57]通过预训练模型 BERT 学习最佳提示模板,将文本分类任务转化为完形填空任务,通过预测填充词并将其映射到标签来获取最终结果。Wang L 等人^[6]基于知识引导,探讨了知识与文本标签的关系,并强调了利用知识提升文本分类效率的重要性。文中提出了两种知识应用方法:一种是直接编码到提示模板中,另一种是通过多任务模型同时处理分类和知识,在少样本任务中表现出色。Hu T 等人^[58]介绍了一种改进的中文 FSTC 方法,即 CIPLUD,该方法结合了提示学习和无标签数据的使用。方法利用预训练语言模型构建了多掩码优化提示学习模块和无标签数据利用模块,通过迭代优化过程实现对少量文本数据的分类。

多标签文本分类是指将一个文本样本分配给多个标签的任务。在多标签文本分类中,每个文本可以被分配一个或多个标签,而不仅仅是单个标签。这种任务能更全面地描述文本的内容和特征。多标签文本分类因其对实际应用的贡献受到学者的广泛关注。多标签文本分类的关键挑战之一在于如何提取和利用标签之间的相关性。然而,在一个复杂且未知的标签空间中,直接建模标签之间的相关性是非常具有挑战性的。

Wang H 等人^[56]通过将原始标签空间映射到由 k 个词组成的标签词集合中,可以计算每个类别的预测概率不训练和集成多个模型的情况下利用多个标签,从而简化了模型的设计和训练过程。Wei L 等人^[59]探讨了将练习与知识概念关联以实现多标签文本分类。强调练习与知识概念之间的语义高度相关,但往往缺乏训练数据。为解决这个问题,提出了 PTMLTC 方法,通过统一模板预测练习与知识概念的相关性得分,进而选择与练习相关的多个知识概念。Song R 等人^[60]设计

了一套用于多标签文本分类的模板,将标签融入预训练语言模型的输入中,并通过掩码语言模型(MLM)进行联合优化。通过自注意力机制,捕捉标签之间的相关性以及标签与文本之间的语义信息,从而有效提高模型性能。

在过去的几年,许多研究者都提出了基于提示学

习的文本分类方法,如表7所示,将提示学习在特殊场景的应用制成表格。此表中的文本分类应用包括新闻分类(NC)、情感分类(SC)、主题分类(TC)、新闻标题分类(NHC)、自然语言推理(NLI)、情感分析(SA)、多标签文本分类(MLTC)、下一句预测(NSP)等应用。

表7 提示学习在特殊场景的应用

Table 7 Prompt Learning applications in special scenarios

特殊场景	时间	提示方式	方法	应用	评估指标
零样本	2021	离散提示	RoBERTa-large	SC, TC	Acc, F1
	2021	离散提示	RoBERTa	NSP	Acc
	2022	人工提示	BERT	NHC	Acc
	2022	连续提示	BERT	SC	F1
小样本	2021	人工提示	RoBERTa	NC, NLI	Acc, SD
	2022	人工提示	BART-large	TC, SC	Acc, F1
	2022	离散提示	RoBERTa	SC, NC	Acc
	2022	离散提示	RoBERTa-large	SA, NLI	Acc, F1
	2023	连续提示	RoBERTa-wwm	SA, NHC	F1
	2023	离散提示	OpenPrompt	NHC	Acc, F1
多标签	2023	连续提示	CIPLUD	SA	Acc
	2022	离散提示	RoBERTa-large	SA, NLI	Acc, F1
	2022	连续提示	Roberta/Bert	MLTC	precision
	2023	人工提示	RoBERTa-large	SA	micro-F1

5 文本分类常用的标签数据集

标签数据集在文本分类领域中起着关键作用,已成为影响这一研究发展的重要因素。为了便于后续研究,这里对文本分类研究中的开源数据进行了梳理,从任务类型、类别数目、训练集数、测试集数、相关文献等方面总结了常用文本分类标签数据集,如表8

所示。提示学习在文本分类方面已经取得了显著的进展,几乎与全微调相媲美,甚至在某些数据集上超越了它如表9所示,本文选择了文本分类中常用的多个数据集,并应用了多种提示学习方法,其中包括手工设计提示、离散提示以及连续提示。我们在相同的数据集上进行了与全微调方法的比较,结果表明提示学习方法已经逐渐接近全微调方法的效果。

表8 常用的标签数据集

Table 8 Common labeled datasets

数据集	任务类型	类别数目	训练集	测试集	相关文献	简介
QQP	释义性	2	363, 846	40, 431	[32][42][47][48][49][55][58]	社区问答网站 Quora 中问题对的集合。
MRPC	释义性	2	3, 668	408	[32][42][47][48][49][56]	从新闻源中自动抽取句子对话料库。
MRPC	释义性	2	3, 668	408	[32][42][47][49][49][56]	从新闻源中自动抽取句子对话料库。
QNLI	自然语言推理	2	104, 743	5, 463	[32][42][48][49][50][56][58]	从斯坦福问答数据集, SQuAD 转换而来的。
SNLI	自然语言推理	3	549, 367	9, 842	[42][47][49]	斯坦福大学发布用于自然语言推理任务的数据集。
RTE	自然语言推理	2	549, 367	9, 842	[32][42][40][42][47][48][49][50][56][58]	取自文本蕴含挑战赛数据, 和维基百科构建。
MNLI	自然语言推理	3	392, 702	9, 796	[20][32][39][42][47][48][50][54][56]	纽约大学与 AI2 合作创建多样性 NLP 推理数据集。

CMNLI	自然语言推理	3	400,000	50,000	[40]	清华大学自然语言处理与人工智能研究中心发布。
STS-B	句子相似性	2	5,749	1,500	[48]	从新闻、视频、图像标题提取的句子集。
SST-2	情感分类	2	67,349	872	[25][26][40][42][48][50][56]	MR 的一个扩展数据集。
Unified Emotion	情感分析	5	16,000	7,700	[51][52]	通过整合多个公共情感数据集的情感标签构建。
DuEL2.0	情感分类	3	2,000	600	[50]	由北京大学自然语言处理与人机交互实验室发布。
20Newsgroups	主题分类	20	16,000	4,000	[20][60]	由 18000 多篇新闻文章中组成。
AG's News	主题分类	4	4,000	4,000	[20][43][51][52]	来自不同类别的新闻文章标题。
BBC News	主题分类	5	1,780	445	[51]	来自 BBC 新闻网站的大约 2,225 篇新闻文章。
DBPedia	主题分类	14	560,000	70,000	[43][59][60]	从维基百科中提取出的结构化信。
THUCNews	新闻文本分类	10	500,010	10,000	[6]	根据新浪新闻 RSS 订阅频道数据筛选过滤生成。
Tnews	新闻分类	15	53,360	10,000	[40][55][57][58]	今日头条的新闻版块。
BoolQ	问答	2	9,427	3,270	[33][34][40][48][49]	由谷歌公司建立的阅读理解数据集。
Yahoo News	问答	31	140,000	5,000	[20][52]	由康奈尔大学发布。

表 9 提示学习方法与全微调方法在数据集上比较

Table 9 Comparison of prompt learning methods and full fine-tuning on datasets

数据集	Full	手工提示方法		离散提示方法				连续提示方法	
		PET ^[20]	Proze ^[51]	AUTOPROMPT ^[25]	LM-BFF ^[26]	EFL ^[49]	AMuLab ^[56]	P-tuning ^[33]	PPT ^[40]
SST-2	95.0	86.0	/	91.4	93.0	96.9	93.4	/	94.4
MR	87.7	80.0	/	/	90.8	92.5	/	87.0	87.1
CR	91.0	88.9	/	/	89.4	92.5	/	91.7	90.9
BQ	47.52	53.6	/	/	76.4	/	/	68.5	/
AG's News	82.4	84.2	69.0	/	/	85.9	/	/	/
TNEWS	51.1	54.7	/	/	70.4	55.7	/	55.9	/
INEWS	44.5	49.92	/	/	68.7	/	/	67.3	/
MNLI	73.3	/	/	65.0	75.4	85.3	68.5	/	64.9
QNLI	93.3	/	64.6	/	/	/	69.6	/	68.8
RTE	80.9	/	/	/	/	90.5	69.4	70.8	67.9
Yahoo News	73.8	/	/	/	/	/	/	/	/

6 应用比较

基于提示学习的文本方法越来越广泛应用于文本分类领域,包括新闻分类、新闻标题分类、自然语言理解、句子对分类、情感分析以及情绪分析等自然

语言处理领域。但是不同的文本分类应用,所使用提示学习方法的侧重点有所不同。表 10 列出了不同提示学习方法在以上六种不同领域的具体做法,以及各方法的优点和难点问题。

表 10 提示学习方法于文本分类的应用

Table 10 English applying prompt learning methods to text classification

应用领域	主要提示学习方法	具体做法	主要优点	主要难点
新闻分类	PET	重构造输入,生成填空,为未标记示例分配软标签。	利用预训练模型知识、定义填空问题模式。	某些填空问题模式性能差。
	PPT	以预训练的提示信息调	提高模型性能、和保持	需合理初始化提示

		整语言模型。	参数效率。	标记。
新闻标题分类	Prompt-Tuning	添加提示标记,提升新闻标题分类性能。	节省参数和计算资源。	人工参与选取合适的提示。
	P-Tuning	优化连续提示改进预训练性能。	提高准确度,缓解过拟合。	选择合适的提示和适应不同的任务。
自然语言推理	PET	自然语言模式重构,生成填空式短语。	可在少量标注样本的情况下进行训练和推理。	某些填空问题模式性能差。
	AUTOPROMPT	自动生成提示。	自动生成提示,有效提取预训练模型知识。	不易用提示引出某些预训练模型知识。
	Prompt-Tuning	添加提示标记提高推理任务性能。	调整提示适应任务,提高鲁棒性和个性化。	提示设计需人工参与且易出错。
	P-Tuning	添加连续提示标记,提升自然语言理解性能,无需改变模型参数。	在连续空间中自动搜索更好的提示来改进预训练模型。	在连续空间中搜索最佳提示需要大量计算资源和时间。
句子对分类	LM-BFF	对输入句子生成嵌入表示,根据相似度选择训练实例。	自动选择相似示例,提升模型性能。	示例和模型输入受限,需谨慎选择示例。
	WRAP	通过初始化提示标记引导模型分类。	提升模型性能,解决多任务。	填空题形式会降低模型表现。
情感分析	Prompt-Tuning	通过调整提示影响模型输入处理,提高性能。	参数高效、鲁棒性提高和泛化能力增强	提示设计受限输入长度,需要人工参与
	PPT	以提示信息将其转化为单句分类任务。	通过预训练提供更好的初始化。	选择合适提示词。
	Prefix-Tuning	通过前缀影响自回归模型,优化情感分析任务。	优化连续的前缀来实现对生成内容的精细控制。	选择和优化合适的前缀。
情绪分析	AUTOPROMPT	使用原任务和触发词生成提示,输入到语言模型中。	无需微调,可以自动生成提示语。	模型对于提示语的上文敏感。
	Prefix-Tuning	优化前缀引导语言模型产生正确分析。	可微调模型,提高性能。	如何选择和优化合适的前缀。

7 总结与展望

本综述对提示学习在文本分类中的应用和研究进行了综合概述。提示学习是一种通过引入任务描述或问题来指导模型生成所需的分类输出的方法,能够在样本数量有限的情况下实现文本分类,弥补了传统方法在文本分类中的局限性。值得注意的是,提示学习不仅在提高分类性能方面表现出色,而且具有良好的可解释性。通过对提示的设计和应用的详细研究,我们发现提示学习方法能够提供对模型决策的清晰解释,使得在不同任务和场景下更容易理解模型的工作原理。提示学习在文本分类中的应用呈现多样化的侧重点,涵盖了多种提示方法混合的策略、基于外部知识的增强策略、提示学习与迁移学习结合的协同策略、零样本、小样本、多标签场景下的提示学习。其中多种提示方法混合的策略通过综合不同类型的提示提高模型的综合理解能力,使其更好地适应不同任务和语境;基于外部知识的增强策略利用外部知识库提高语境理解和泛化性;提示学习与迁移学习协同策略通过结合先验知识实现迁移学习,提高在新任务上的学习效率。这些策略的优势取决于任务需求,综合运用这些方法有望为文本分类任务带来更全面、高效的解决方案。提示学习为文本分类任务提供了丰富的方法和策略,同时为决策过程的可解释性增添了价值,推动

了该领域的发展。

尽管提示学习在文本分类方面取得了一定的成功,但仍然面临一些挑战及广阔的发展前景。首先是提示设计的难度,需要准确且相关的提示来指导模型。其次是过度依赖提示,导致模型在理解输入文本方面的能力不足。最后对于提示的鲁棒性问题未有受到足够重视,提示的微小变化,如示例顺序的调整、拼写错误或同义词的使用,可能导致模型给出截然不同的结果。深化对提示学习的理解以及与其他相关技术的结合是未来的研究方向。对提示学习的研究可以涉及模型对提示的理解方式,如何将上下文信息与提示结合使用,以及探索提示的表示形式和生成方法等。同时,与其他技术的结合也可以进一步提高文本分类的性能,例如将强化学习或生成对抗网络等方法相结合,以实现更好的分类效果。

参考文献:

[1] BAYER M, KAUFHOLD M A, REUTER C. A survey on data augmentation for text classification[J]. ACM Computing Surveys, 2022, 55(7): 1-39.

[2] MINAEI S, KALCHBRENNER N, CAMBRIA E, et

- al. Deep learning--based text classification: a comprehensive review[J]. *ACM computing surveys (CSUR)*, 2021, 54(3): 1-40.
- [3] LI Q, PENG H, LI J, et al. A survey on text classification: From traditional to deep learning[J]. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 2022, 13(2): 1-41.
- [4] WU H, LIU Y, WANG J. Review of Text Classification Methods on Deep Learning[J]. *Computers, Materials & Continua*, 2020, 63(3): 1309-1321.
- [5] BAYER M, KAUFHOLD M A, REUTER C. A survey on data augmentation for text classification[J]. *ACM Computing Surveys*, 2022, 55(7): 1-39.
- [6] WANG L, CHEN R, LI L. Knowledge-Guided Prompt Learning for Few-Shot Text Classification[J]. *Electronics*, 2023, 12(6): 1486.
- [7] ZHANG P, CHAI T, XU Y. Adaptive prompt learning-based few-shot sentiment analysis[J]. *Neural Processing Letters*, 2023: 1-14.
- [8] GU J, HAN Z, CHEN S, et al. A systematic survey of prompt engineering on vision-language foundation models[J]. *arXiv preprint arXiv:2307.12980*, 2023.
- [9] PETERS M, NEUMANN M, IYYER M, et al. Deep Contextualized Word Representations[J]. 2018.DOI: 10.18653/v1/N18-1202.
- [10] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[EB/OL].[2020-09-26].https://s3-us-west-2.amazonaws.com/openai-assets/research-covers/language-unsupervised/language_understanding_paper.pdf.
- [11] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. *arXiv preprint arXiv:1810.04805*, 2018.
- [12] FU Z, YANG H, SO A M C, et al. On the effectiveness of parameter-efficient fine-tuning[C]// *Proceedings of the AAAI Conference on Artificial Intelligence*. 2023, 37(11): 12799-12807.
- [13] HAN X, ZHANG Z, DING N, et al. Pre-Trained Models: Past, Present and Future[J]. 2021.DOI:10.1016/j.aiopen.2021.08.002.
- [14] 陈德光, 马金林, 马自萍, 等. 自然语言处理预训练技术综述[J]. *计算机科学与探索*, 2021, 15(8): 1359-1389.
- CHEN G D, MA J L, MA Z P, et al. Review of Pre-training Techniques for Natural Language Processing[J]. *Journal of Frontiers of Computer Science and Techno*, 2021, 15(08): 1359-1389.
- [15] ZHANG Z, WANG B. Prompt learning for news recommendation[J]. *arXiv preprint arXiv:2304.05263*, 2023.
- [16] CHANG K W, TSENG W C, LI S W, et al. SpeechPrompt: An exploration of prompt tuning on generative spoken language model for speech processing tasks[J]. *arXiv preprint arXiv:2203.16773*, 2022.
- [17] LIU P, YUAN W, FU J, et al. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing[J]. *ACM Computing Surveys*, 2023, 55(9): 1-35.
- [18] PETRONI F, ROCKTÄSCHEL T, LEWIS P, et al. Language models as knowledge bases?[J]. *arXiv preprint arXiv:1909.01066*, 2019.
- [19] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[J]. *Advances in neural information processing systems*, 2020, 33: 1877-1901.
- [20] SCHICK T, SCHÜTZE H. Exploiting cloze questions for few shot text classification and natural language inference[J]. *arXiv preprint arXiv:2001.07676*, 2020.
- [21] JIANG Z, XU F F, ARAKI J, et al. How can we know what language models know?[J]. *Transactions of the Association for Computational Linguistics*, 2020, 8: 423-438.
- [22] YUAN W, NEUBIG G, LIU P. Bartscore: Evaluating generated text as text generation[J]. *Advances in Neural Information Processing Systems*, 2021, 34: 27263-27277.
- [23] HAVIV A, BERANT J, GLOBERSON A. BERTese: Learning to speak to BERT[J]. *arXiv preprint arXiv:2103.05327*, 2021.
- [24] WALLACE E, FENG S, KANDPAL N, et al. Universal adversarial triggers for attacking and analyzing NLP[J]. *arXiv preprint arXiv:1908.07125*, 2019.
- [25] SHIN T, RAZEGHI Y, LOGAN IV R L, et al. Autoprompt: Eliciting knowledge from language models with automatically generated prompts[J]. *arXiv preprint arXiv:2010.15980*, 2020.
- [26] GAO T, FISCH A, CHEN D. Making pre-trained

- language models better few-shot learners[J]. arXiv preprint arXiv:2012.15723, 2020.
- [27] DAVISON J, FELDMAN J, RUSH A M. Commonsense knowledge mining from pretrained models[C]//Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP). 2019: 1173-1178.
- [28] LI X L, LIANG P. Warp -tuning: Optimizing continuous prompts for generation[J]. arXiv preprint arXiv:2101.00190, 2021.
- [29] LESTER B, AL-ROUFI R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[J]. arXiv preprint arXiv:2104.08691, 2021.
- [30] ZHONG Z, FRIEDMAN D, CHEN D. Factual probing is [mask]: Learning vs. learning to recall[J]. arXiv preprint arXiv:2104.05240, 2021.
- [31] QIN G, EISNER J. Learning how to ask: Querying LMs with mixtures of soft prompts[J]. arXiv preprint arXiv:2104.06599, 2021.
- [32] HAMBARDZUMYAN K, KHACHATRIAN H, MAY J. Warp: Word-level adversarial reprogramming[J]. arXiv preprint arXiv:2101.00121, 2021.
- [33] LIU X, ZHENG Y, DU Z, et al. GPT understands, too[J]. AI Open, 2023.
- [34] LIU X, JI K, FU Y, et al. P-tuning v2: Prompt tuning can be comparable to fine-tuning universally across scales and tasks[J]. arXiv preprint arXiv:2110.07602, 2021.
- [35] HAN X, ZHAO W, DING N, et al. Ptr: Prompt tuning with rules for text classification[J]. AI Open, 2022, 3: 182-192.
- [36] ZHANG R, SUN Y, YANG J, et al. Knowledge-Augmented Frame Semantic Parsing with Hybrid Prompt-Tuning[C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [37] PEREZ E, KIELA D, CHO K. True few-shot learning with language models[J]. Advances in neural information processing systems, 2021, 34: 11054-11070.
- [38] AGHAJANYAN A, OKHONKO D, LEWIS M, et al. Htlm: Hyper-text pre-training and prompting of language models[J]. arXiv preprint arXiv:2107.06955, 2021.
- [39] ZHAO M, SCHÜTZE H. Discrete and soft prompting for multilingual models[J]. arXiv preprint arXiv:2109.03630, 2021.
- [40] GU Y, HAN X, LIU Z, et al. Ppt: Pre-trained prompt tuning for few-shot learning[J]. arXiv preprint arXiv:2109.04332, 2021.
- [41] 鲍琛龙, 吕明阳, 唐晋韬等. 与知识相结合的提示学习研究综述[J]. 中文信息学报, 2023, 37(7): 1-12.
- BAO C L, LYU M Y, TANG J T et al. A Survey of Prompt Learning Combined with Knowledge[J]. Journal of Chinese Information Processing, 2023, 37(7): 1-12.
- [42] HU S, DING N, WANG H, et al. Knowledgeable prompt-tuning: Incorporating knowledge into prompt verbalizer for text classification[J]. arXiv preprint arXiv:2108.02035, 2021.
- [43] WANG J, WANG C, LUO F, et al. Towards unified prompt tuning for few-shot text classification[J]. arXiv preprint arXiv:2205.05313, 2022.
- [44] ZHU Y, ZHOU X, QIANG J, et al. Prompt-learning for short text classification[J]. arXiv preprint arXiv:2202.11345, 2022.
- [45] LI J, TANG T, NIE J Y, et al. Learning to transfer prompts for text generation[J]. arXiv preprint arXiv:2205.01543, 2022.
- [46] ZHANG L, GAO X. Transfer adaptation learning: A decade survey[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022.
- [47] VU T, LESTER B, CONSTANT N, et al. Spot: Better frozen model adaptation through soft prompt transfer[J]. arXiv preprint arXiv:2110.07904, 2021.
- [48] WANG C, WANG J, QIU M, et al. Transprompt: Towards an automatic transferable prompting framework for few-shot text classification[C]//Proceedings of the 2021 conference on empirical methods in natural language processing. 2021: 2792-2802.
- [49] WANG S, FANG H, KHABSA M, et al. Entailment as few-shot learner[J]. arXiv preprint arXiv:2104.14690, 2021.
- [50] SUN Y, ZHENG Y, HAO C, et al. NSP-BERT: A Prompt-based Few-Shot Learner Through an Original Pre-training Task--Next Sentence Prediction[J]. arXiv

- preprint arXiv:2109.03564, 2021. 2023, 53(8): 8761-8775.
- [51] HARRANDO I, REBOUD A, Schleider T, et al. ProZe: Explainable and Prompt-Guided Zero-Shot Text Classification[J]. IEEE Internet Computing, 2022, 26(6): 69-77.
- [52] DAN Y, ZHOU J, CHEN Q, et al. Enhancing class understanding via prompt-tuning for zero-shot text classification[C]//ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 4303-4307.
- [53] GUO Y, CODELLA N C, KARLINSKY L, et al. A broader study of cross-domain few-shot learning[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXVII 16. Springer International Publishing, 2020: 124-141.
- [54] MAYER C W F, LUDWIG S, BRANDT S. Prompt text classifications with transformer models! An exemplary introduction to prompt-based learning with large language models[J]. Journal of Research on Technology in Education, 2023, 55(1): 125-141.
- [55] SONG C, SHAO T, LIN K, et al. Investigating Prompt Learning for Chinese Few-Shot Text Classification with Pre-Trained Language Models[J]. Applied Sciences, 2022, 12(21): 11117.
- [56] WANG H, XU C, MCAULEY J. Automatic multi-label prompting: Simple and interpretable few-shot classification[J]. arXiv preprint arXiv:2204. 06305, 2022.
- [57] 于碧辉, 蔡兴业, 魏靖烜. 基于提示学习的小样本文本分类方法[J]. 计算机应用, 2023, 43(9): 2735-2740.
- YU B H, CAI X Y, WEI J X. Few-Shot Text Classification Method Based on Prompt Learning[J]. Journal of Computer Applications, 2023, 43(9): 2735-2740.
- [58] HU T, CHEN Z, GE J, et al. A Chinese Few-Shot Text Classification Method Utilizing Improved Prompt Learning and Unlabeled Data[J]. Applied Sciences, 2023, 13(5): 3334.
- [59] WEI L, LI Y, ZHU Y, et al. Prompt Tuning for Multi-Label Text Classification: How to Link Exercises to Knowledge Concepts?[J]. Applied Sciences, 2022, 12(20): 10363.
- [60] SONG R, LIU Z, CHEN X, et al. Label prompt for multi-label text classification[J]. Applied Intelligence,